DevAgent · 项目演进与成果展示

聚焦大代码库场景下的检索治理、数据构建与路由微调，以下展示核心设计与量化结果。

核心工作

1. 检索策略调整

- **问题**：早期模型在通用问答中容易过检索，不该查库时也会触发 `search_codebase` 。
- **软熔断**：基于 Dense 距离分桶和阈值分析，对无效检索做兜底拦截。
- **Prompt 调整**：根据端到端 bad case 迭代 system prompt 与工具描述，重点优化"是否调用工具"的判断。
- **结果**：一致率从 **63.3%** 提升到 **97.8%**，FP 从 **33** 降到 **2**。

2. 评测拆分

- 第一层评估工具调用是否符合 gold。
- 第二层评估检索后的软熔断效果。
- 第三层引入 **LLM-as-Judge**，按 `bucket + grounding_tier` 评估最终回答质量。
- 评测中区分索引滞后与模型策略问题，避免混淆原因。

3. 大仓库场景与数据飞轮

- 在 `experiments/external/` 中使用 Transformers、FastAPI 等外部仓库建立基准。
- 外部仓基准与主仓 `src/` 索引隔离，避免将主仓结果当成大仓表现。
- 数据按私域、远域、误导场景组织，覆盖"该查库"和"不该查库"两类任务。
- 数据处理流程为机器过滤 + 人工抽样复核，再转为 ShareGPT 格式训练。

4. 首轮 SFT：路由能力

- 基于 Qwen2.5-7B-Instruct 进行 LoRA 微调。
- 本轮目标聚焦三项：JSON 可解析、决策类型正确、工具名正确。
- 不将 arguments 与金标逐字一致作为本轮主指标。
- 结果： `decision_type` 一致率从 **56.0%** 提升到 **98.0%**，JSON 结构合法率达到 **100%**。

5. 后续方向

- 评测侧继续补充召回后回答质量指标，参考 RAGAS 类方法。
- 训练侧从路由 SFT 延伸到检索后生成、偏好对齐与 Self-RAG 类后训练。

核心指标快照

A. 检索侧：距离分桶与软熔断（90 条样本）

分桶	n	mean	median	min–max
domain	40	0.838	0.884	0.502–1.183
far_general	28	1.205	1.194	1.034–1.377
term_near_no_rag	12	1.055	1.133	0.638–1.334
misleading_edge	10	0.865	0.873	0.497–1.193
域外合并	50	1.101	1.156	0.497–1.377

> 域内与域外分布有重叠。阈值 **T=1.12** 可拦截 **62%** 域外样本，但会误伤 **7.5%** 域内样本， 说明软熔断适合做兜底，不适合作为唯一判断依据。

B. 端到端工具调用一致率

阶段	一致率	FP	FN
首轮（旧 Prompt）	57/90 **(63.3%)**	33	0
Prompt v2	88/90 **(97.8%)**	**2**	0

> 对于必须查库的 35 条 `must_ground` 样本，两版测试的 FN 都为 0。

C. Phase 2A 路由微调效果（50 条验证集）

100%
JSON 结构合法率

98.0%
决策类型一致率

96.8%
工具名一致率

评测维度	Base	LoRA	API
可解析为 JSON	96.0%	**100%**	100%
JSON 结构合法	82.0%	**100%**	98.0%
decision_type 一致	56.0%	**98.0%**	92.0%
工具名一致	86.7%	**96.8%**	90.3%

结论： 首轮 LoRA 已经把路由决策和结构化输出做稳，后续可以继续往检索后生成和偏好对齐推进。

关联文档

文档	内容
评估/08-软熔断Phase1与端到端评测.md	软熔断测试与首轮评测
评估/09-prompt与工具描述优化后复测.md	Prompt v2 复测结果
评估/10-LLM-as-Judge-v1.md	Judge rubric 与分层评测设计
评估/11-Phase2A路由SFT微调报告.md	Phase 2A 路由微调结果
experiments/data_flywheel/README.md	数据飞轮设计